

Hlboké neurónové siete


Prednáška č. 6 časť 1

GAN siete , Autoenkódery




Autoenkóдеры

- Časti – enkóder, zakódovaný vstup, dekóder
- Učenie bez učiteľa (nepotrebuje predkladaný vzor)
- Kompresia, redukcia vstupu
- Učenie backpropagation
- Vstupný aj výstupný obraz je rovnaký
- Nie je cieľom, aby autoenkóder bez chyby dekódoval vzor

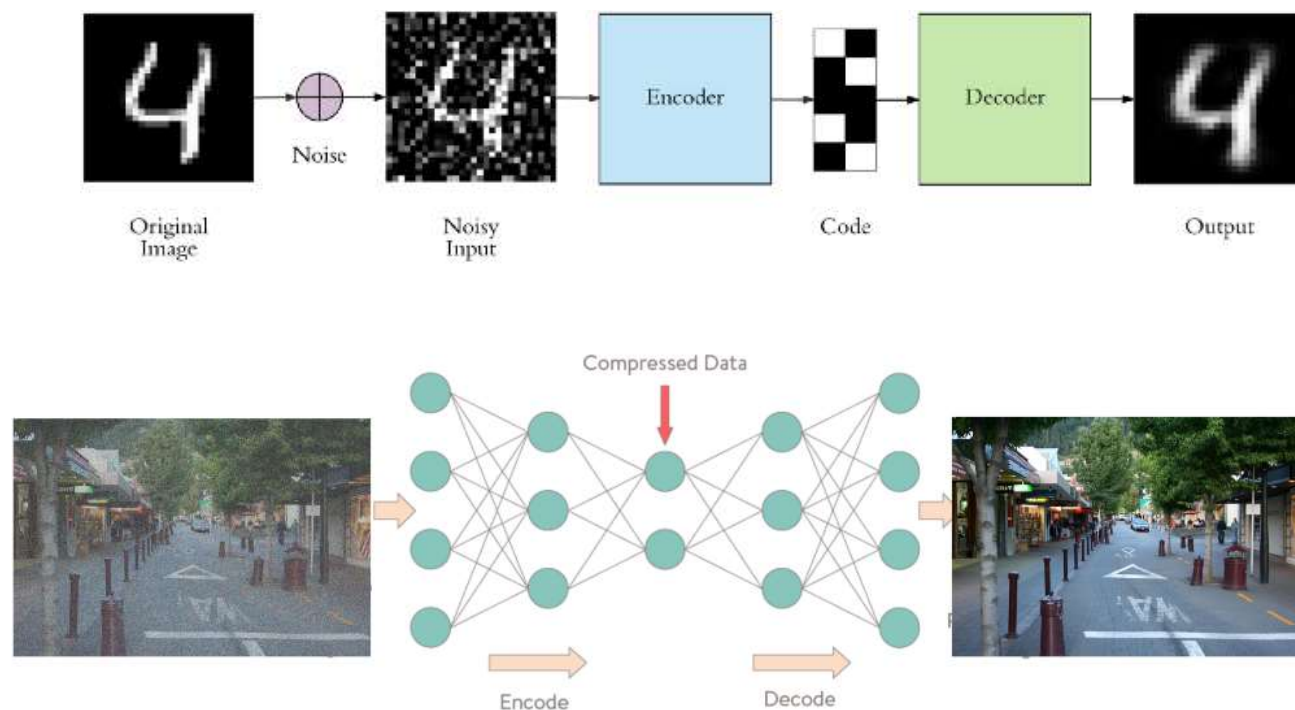



Aplikácie Autoenkóderov


- Detekcia anomálií, chybných častí na obraze
- Obraz v obraze – dopočítanie chýbajúceho obrazu
- Odšumenie obrazu, zvuku
- Segmentácia obrazu – detekcia nádoru, orgánov na snímkoch



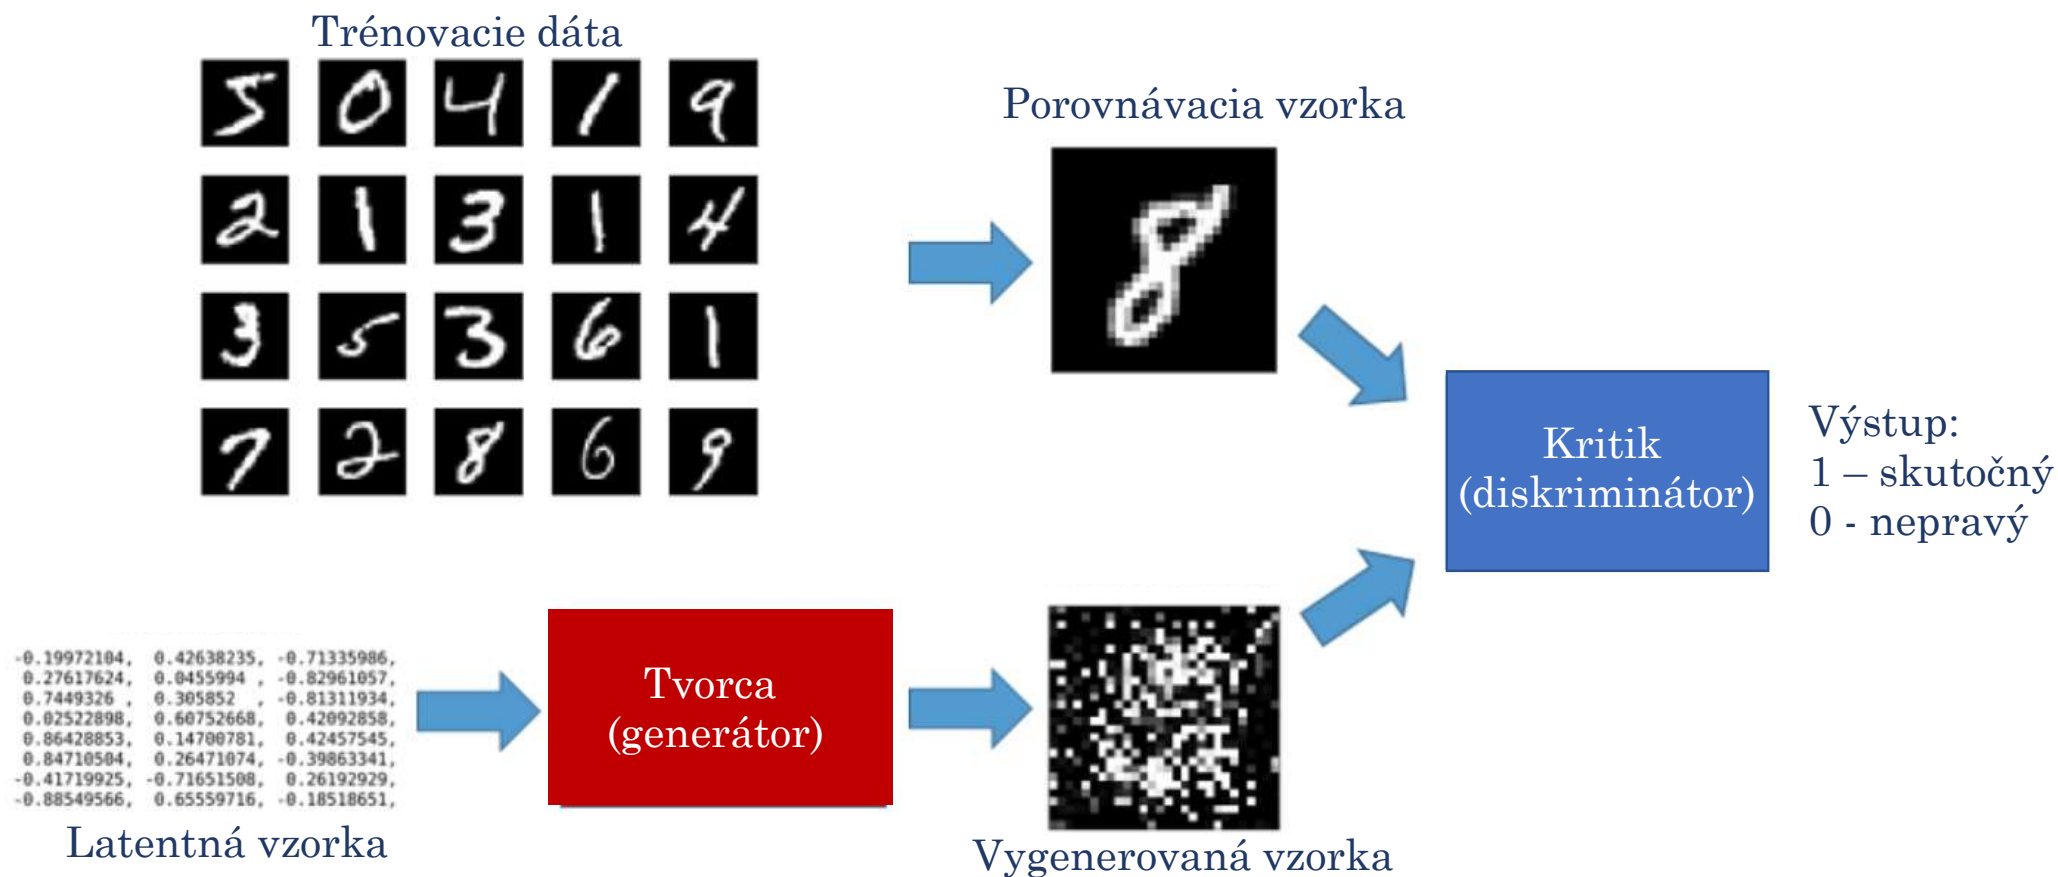
Odšumenie obrazu autoenkóderom



- Obraz v obraze – dopočítanie chýbajúceho obrazu
- Segmentácia obrazu – detekcia nádoru, orgánov na snímkoch



Generative Adversarial Networks (GANs) - Konfrontačná sieť




Konfrontačné učenie

- Pri tréovaní využívame algoritmus spätného šírenia chyby
- Princíp konfrontácie spočíva v dvoch súperiacich neurónových siet'ach, Generátora a Diskriminátora.
- Generátor generuje dáta na základe vstupu
- Diskriminátor vyhodnocuje dáta a snaží sa klasifikovať, či sú falošné
- Ako pravé dáta sú vyhodnocované vstupy pochádzajúce z datasetu a naopak, falošné sú tie, čo pochádzajú z Generátora.

Optimalizačný problém


$$\min_{G,D} V(G,D) = \mathbb{E}_{x \sim p_d(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$



Goodfellow I. J., Pouget-Abadie J., Mirza M., Xu B., Warde-Farley D., Ozair S., Courville A., Bengio Y.: Generative Adversarial Nets, 2014, arXiv, 1406.2661, stat.ML


Conditional GAN - Podmienená Konfrontačná sieť

Obmedzenie (nasmerovanie)
generovania a vyhodnocovania obrazu
Podmienkami x



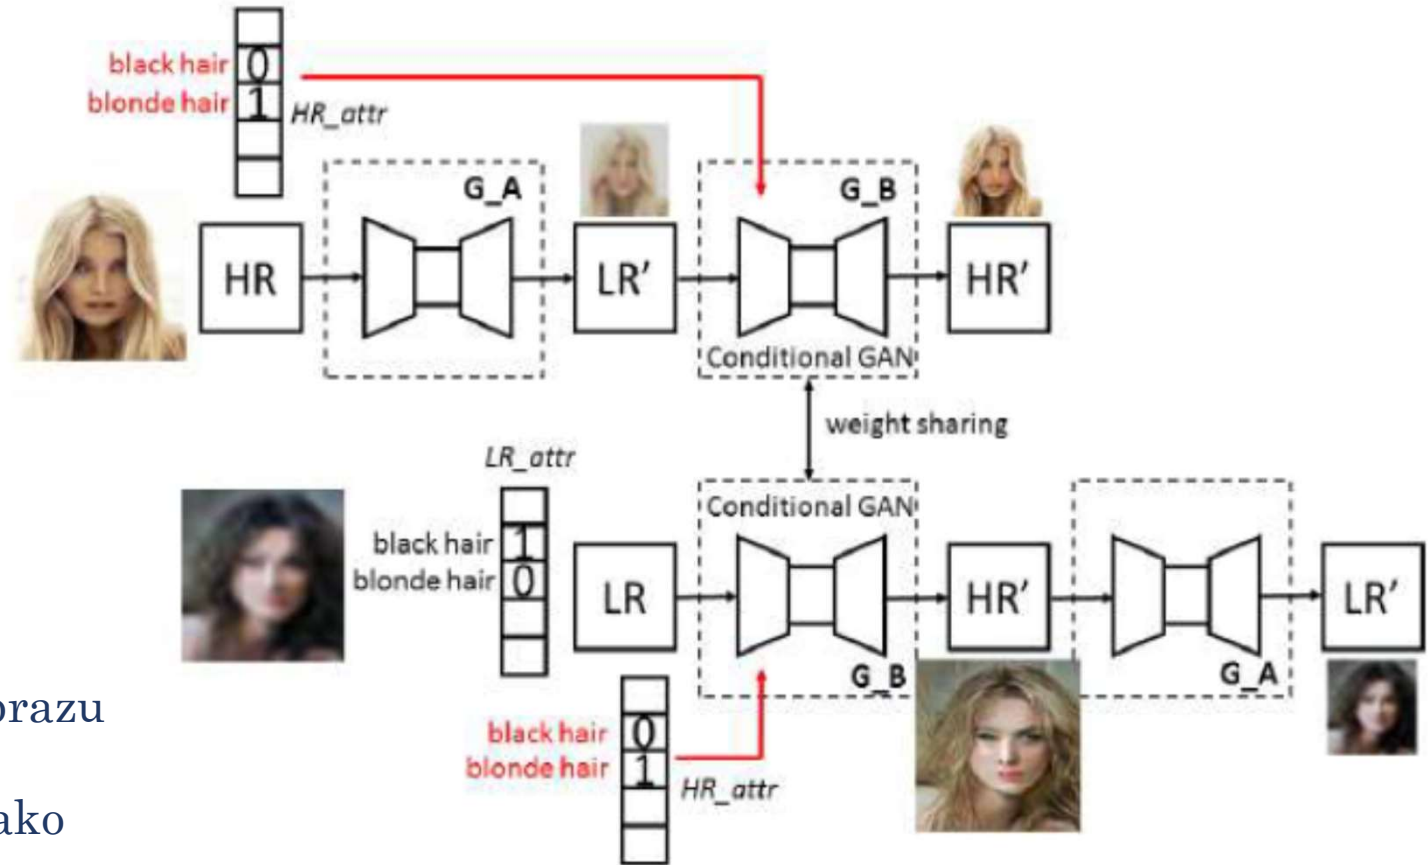
Príklad:

$$\min_G \max_D (\mathbb{E}_{y,x \sim p_{data}(y,x)} [\log D(y, x)] + \mathbb{E}_{x \sim p_x, z \sim p_z(z)} [\log(1 - D(G(z, x), x))])$$




Cycle GAN - Attribute Guided Face Generation Using Conditional CycleGAN

- Vstupom do siete je obraz s tvarovými atribútmi
- Upravuje vstupný obraz podľa zadanych tvarových atribútov
- Generátor je tvorený autoenkóderom
- Vektor náhodného šumu sa nahrádza obrazom
- Obmedzené množstvo dát v datasetoch
- Fixné podmienky na úpravu obrazu
- Konfrontačné tréovanie autoenkódera je jednoduchšie ako pri šume



DCGAN - Deep Convolutional GAN


- Realistickejší obraz – transformáciou pomocou konvolučných vrstiev



Radford A., Metz L., Chintala S.: Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks, arXiv, 1511.06434, cs.LG

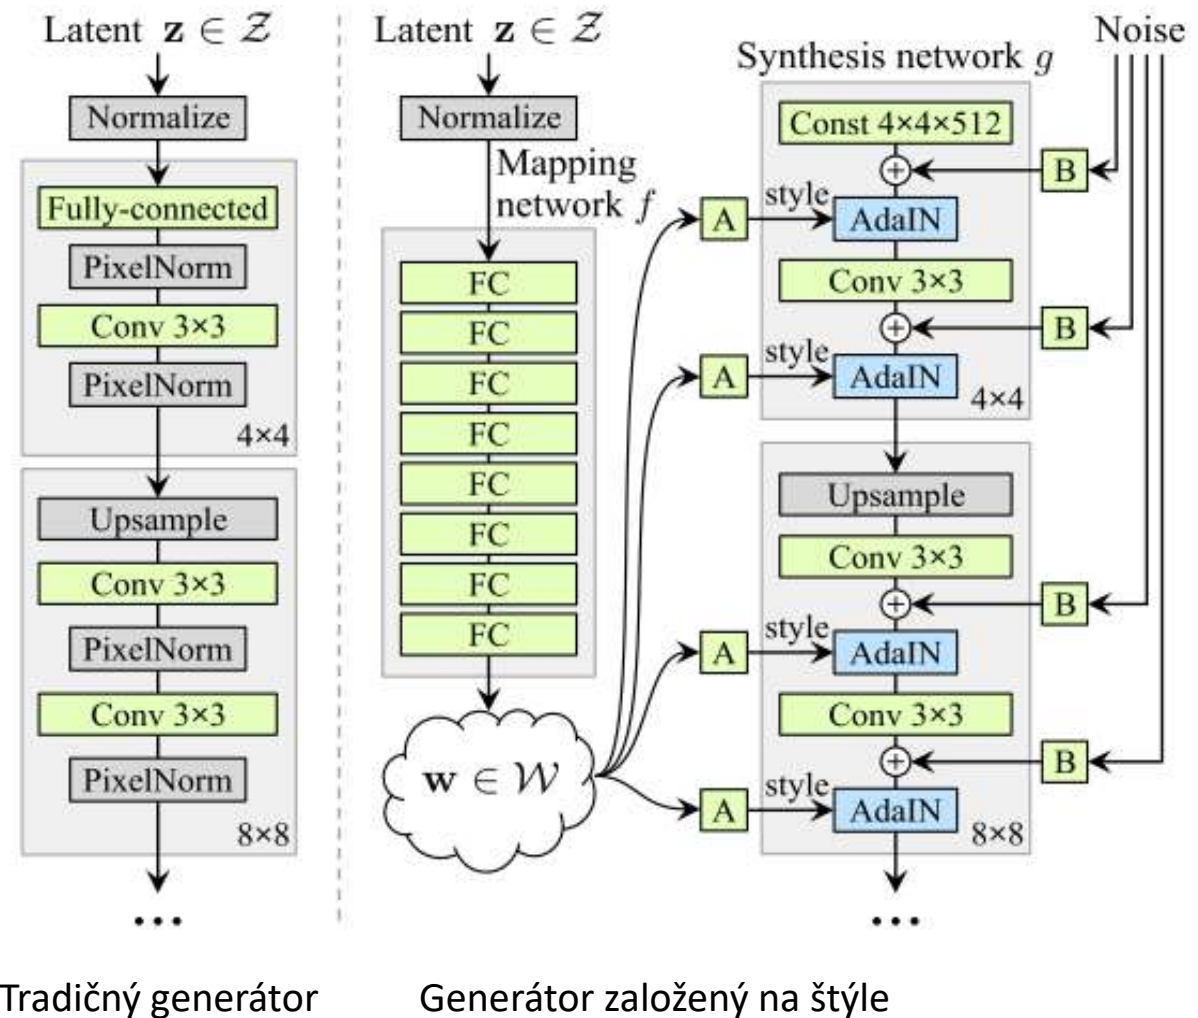
Progressive GAN -

- Pridávanie konvolučných vrstiev v procese tréovania
- Skracuje tréovanie siete
- Zvyšuje stabilitu tréovania



Style GAN -

- Štandardný generátor vytvára obraz konvolúciami
- Style generátor – vytvára mapovanie vstupného priestoru, z ktorého váhovaním (matica W) ovládame rôzne štýly pomocou adaptívnej normalizácie (AdaIN) pri konvolučnej vrsve
- Štýlmi definujeme vybrané vlastnosti obrazu
- Gausov šum sa privádza ku každej konvolúcii
- Štandardný generátor – realizuje afinnú transformáciu vstupného obrazu
- Style generátor – aplikuje naučené škálovacie faktory pre jednotlivé kanály šumu
- Style generátor má 26,2 milióna učiacich parametrov (standard 23,1 milióna)



Tradičný generátor

Generátor založený na štýle

KARRAS, Tero; LAINE, Samuli; AILA, Timo. A style-based generator architecture for generative adversarial networks. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2019. p. 4401-4410.

- Dekonvolúcia – Transponovaná konvolúcia (Transposed Convolution)


Transposed Convolutions

2x2 convolution, stride of 1 and a pad of 0

$$\begin{aligned} 4 * 3 &= 12 \\ 2 * 1 &= 2 \\ 12 + 2 &= 14 \end{aligned}$$

6	14	4
2	17	21
0	1	5

Output





eng. "Inceptionalism" – obrazové halucinácie

eng. “Neural Style Transfer”




Gatys, L. A., Ecker, A. S., & Bethge, M. (2015). A neural algorithm of artistic style. arXiv preprint arXiv:1508.06576.
Zdroje obrázkov: medium.com

Edmond De Belamy

- Generatívne umenie (GAN)
- Výsledný obraz vytlačený na plátno
- Predaný v dražbe za rekordnú sumu (432 500 USD)




La Comte De Belamy



Edmond De Belamy


Generovanie ľudských tvárí



Karras, T., Laine, S., & Aila, T. (2018). A style-based generator architecture for generative adversarial networks. arXiv preprint arXiv:1812.04948.

Zdroje obrázkov: theverge.com

CartoonGAN (2018)




Chen, Y., Lai, Y. K., & Liu, Y. J. (2018). Cartoongan: Generative adversarial networks for photo cartoonization. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (pp. 9465-9474).

Zdroje obrázkov: github.com


Labels to Street Scene



Labels to Facade




BW to Color



Aerial to Map



Day to Night



Edges to Photo



Isola, P., Zhu, J. Y., Zhou, T., & Efros, A. A. (2017). Image-to-image translation with conditional adversarial networks. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 1125-1134).
 Zdroje obrázkov: phillipi.github.io

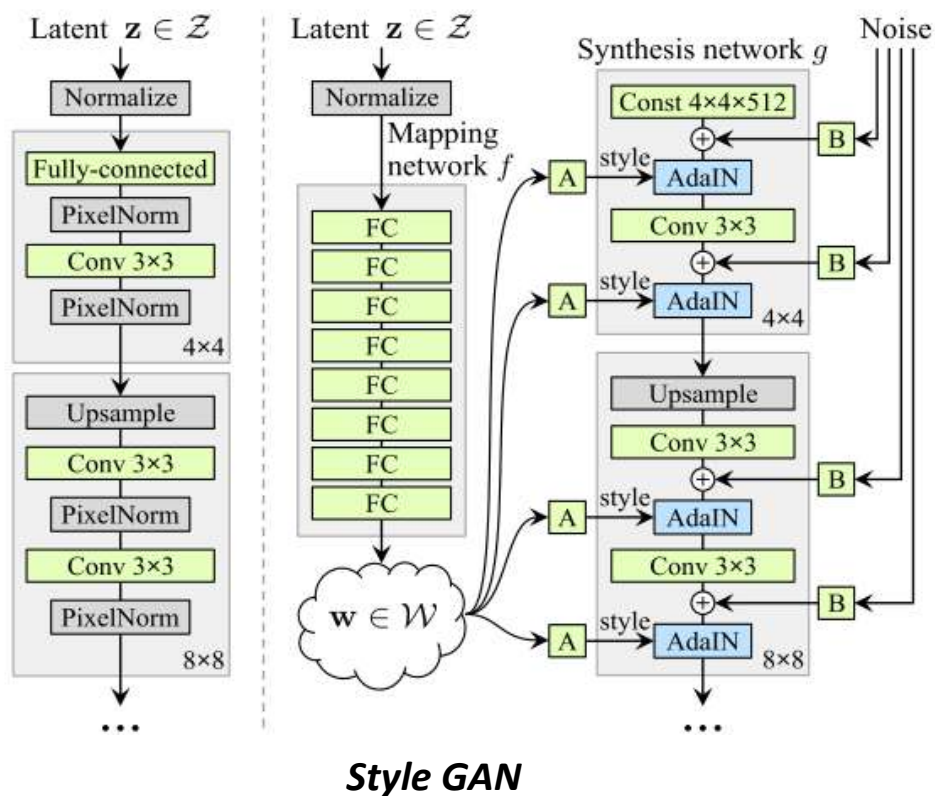
eng. “Deep Fakes”





Chesney, R., & Citron, D. (2018). Deep Fakes: A Looming Crisis for National Security, Democracy and Privacy. The Lawfare Blog.
Zdroje obrázkov: medium.com

Ing. Michal Kováč

Generovanie syntetických obrazov
v medicíne metódami hlbokého učenia





Ďakujem Vám za pozornosť.
(priestor na Vaše otázky)

