

# Hlboké neurónové siete


## Prednáška č.6

# Aplikácie hlbokých neurónových sietí




## Aplikácie v Robotike

- Vizuálna kontrola prostredia (Computer Vision)
- Rozpoznávanie, klasifikácia z obrazu
- Detekcia objektov
- HMI – rozpoznávanie gest, reči, tváre
- Rozpoznanie textu
- Riadenie systémov



## Aplikácie v Robotike

- Vizuálna spätná väzba (Robot Buxter)
- snaha naučiť sa 18 pozícií úchopu predmetu
- 50 tisíc pokusov (700 robot-hodín)
- Architektúra CNN podobná AlexNet



Pinto, L., & Gupta, A. (2016, May). Supersizing self-supervision: Learning to grasp from 50k tries and 700 robot hours. In 2016 IEEE international conference on robotics and automation (ICRA) (pp. 3406-3413). IEEE.

## Aplikácie v Robotike


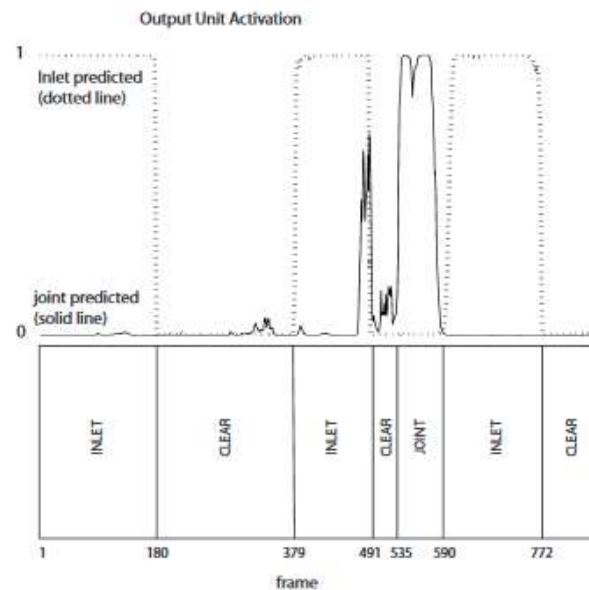
- Robotom asistovaná operácia (vizuálna spätná väzba)
- Robot DaVinci (vstupom informácie zo senzorov – nie priamo obraz)



Wang, Z., & Fey, A. M. (2018). Deep learning with convolutional neural network for objective skill evaluation in robot-assisted surgery. *International journal of computer assisted radiology and surgery*, 13(12), 1959-1970.

## Aplikácie v Robotike

- vizuálna inšpekcia kanalizačných potrubí
- vstupom do CNN obraz zo všesmerovej kamery
- výstupom je časová analýza záznamu prechodu kanalizačným potrubím






## Aplikácie v Robotike


- detekcia poškodených obrobkov - vizuálna kontrola
- vstupom do CNN je obraz 512x512 z kamery
- Binárny klasifikačný problém dobrá / poškodená
- Trénovacie data (73,5%)

Dataset	Rozlíšenie	Celkový počet snímkov	Počet poškodených
Neaugmentovany	512 x 512 x 1	1300	781


Model	Vstupný rozmer	Normalizácia vstupu
Inception V3	299x299x3	<-1,1>
ResNet50 V2	224x224x3	<-1,1>



## Výsledky detekcie – Inception sieť





Optimalizačná metóda	Krok učenia	Dropout "rate"	Úspešnosť klasifikácie tréning (Max)	Úspešnosť klasifikácie validácia (Max)	Úspešnosť klasifikácie testovanie
Adam	1e-3	0,1	98,5	100	99,4



## Aplikácie v Robotike

- vizuálna inšpekcia slnečných panelov
- detekcia poškodení panelov (mikropraskliny, praskliny, odtrhnuté zberacie pásy, prasklinami oddelené plochy, straty medzi plochami, ...)
- CNN je natrénovaná na obrazoch rôznych poškodení
- snímanie obrazu napr. termokamerou pomocou dronu





## Aplikácia – zváranie materiálov – Detekcia typu trajektórie

- nasnímaný obraz z kamery
- trénovaná CNN na obrazy z kamery, klasifikácia do 10 skupín typov trajektorií

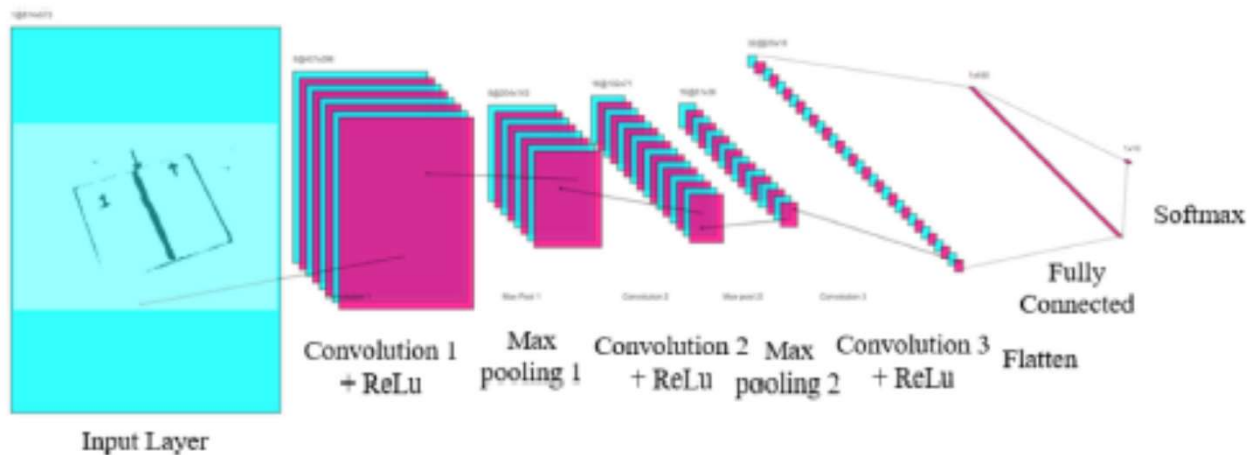



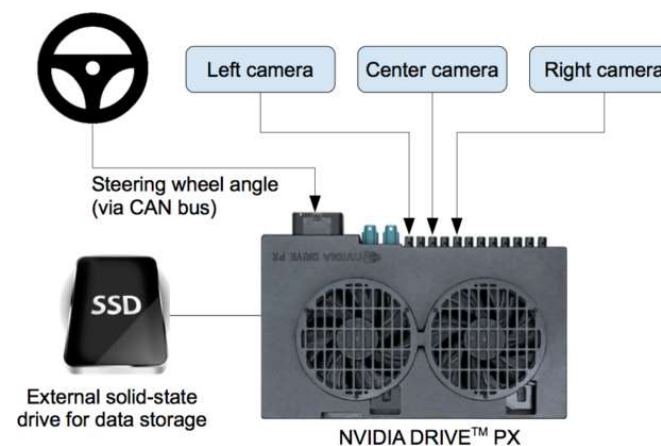

Fig. 1. Description of Different layers in 2D CNN for Weld Shapes Classification.



## Aplikácie v automobilovom priemysle


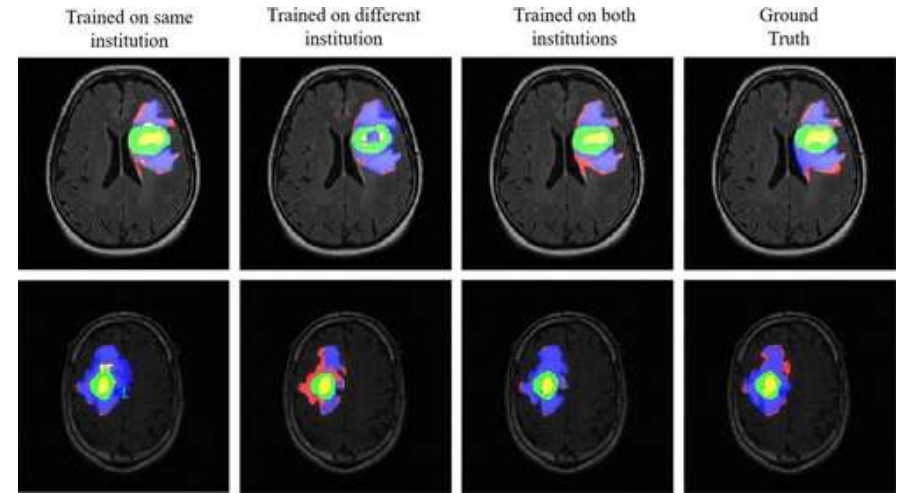

- detekcia prekážok, auta, ľudí
- rozpoznanie značiek
- predikcia zakrivenia cesty, detekcia čiar

Radius of Curvature = 10739(m)  
Vehicle is 0.34(m) left of center





## Aplikácie v Medicíne

- Diagnostika z obrazu – vyhodnotenie MRI, CT, RTG, USG, histopatológii snímok
- Analýza meraných signálov EKG, EEG, EMG
- Telemedicína, Health Chatbot



## Aplikácie v Medicíne

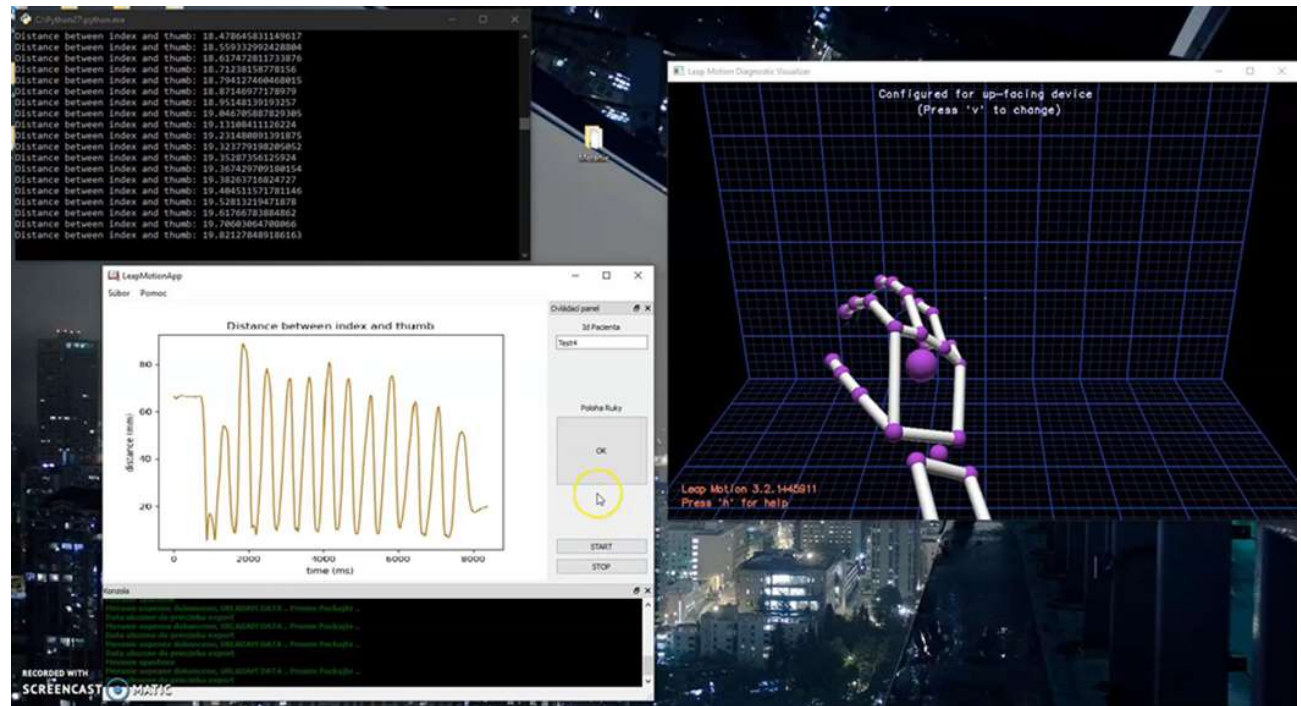
- Rozpoznávanie signálov (EKG, EEG, EMG) pomocou CNN





## Aplikácie v Medicíne

- Rozpoznávanie neurologických ochorení – Finger Tapping Test




- Detekcia príznakov – klasifikácia MLP sieť
- Meraný signál – LSTM sieť






## Aplikácie v Medicíne

- detekcia poškodenia očnej sietnice pri cukrovke



## Aplikácie v Medicíne

- detekcia poškodenia očnej sietnice pri cukrovke



## Aplikácie v Medicíne

### Kaggle databáza – stupne poškodenia



0 – 25790




1 - 2443



2 - 5292



3 – 873 (2087)




4 – 708 (1914)

### Predtrénované siete – transfer learning

- ❖ AlexNet
- ❖ VGGnet
- ❖ ResNet
- ❖ GoogLeNet.
- ❖ Inception

### HOW A DEEP NEURAL NETWORK SEES



## Aplikácie v Medicíne

**2 triedy – Kaggle dataset - nepoškodené 25790 / poškodené 23 472 (stupeň 1 až 4)**

### VGG

Pokus	1	2	3	4	5	Min	Max	Mean
Úspešnosť Trénovacie Data	94,66%	93,41%	94,64%	93,12%	91,47%	91,47%	94,66%	93,46%
Úspešnosť Testovacie Data	86,46%	86,89%	92,31%	90,08%	90,35%	86,46%	92,31%	89,22%

### Resnet

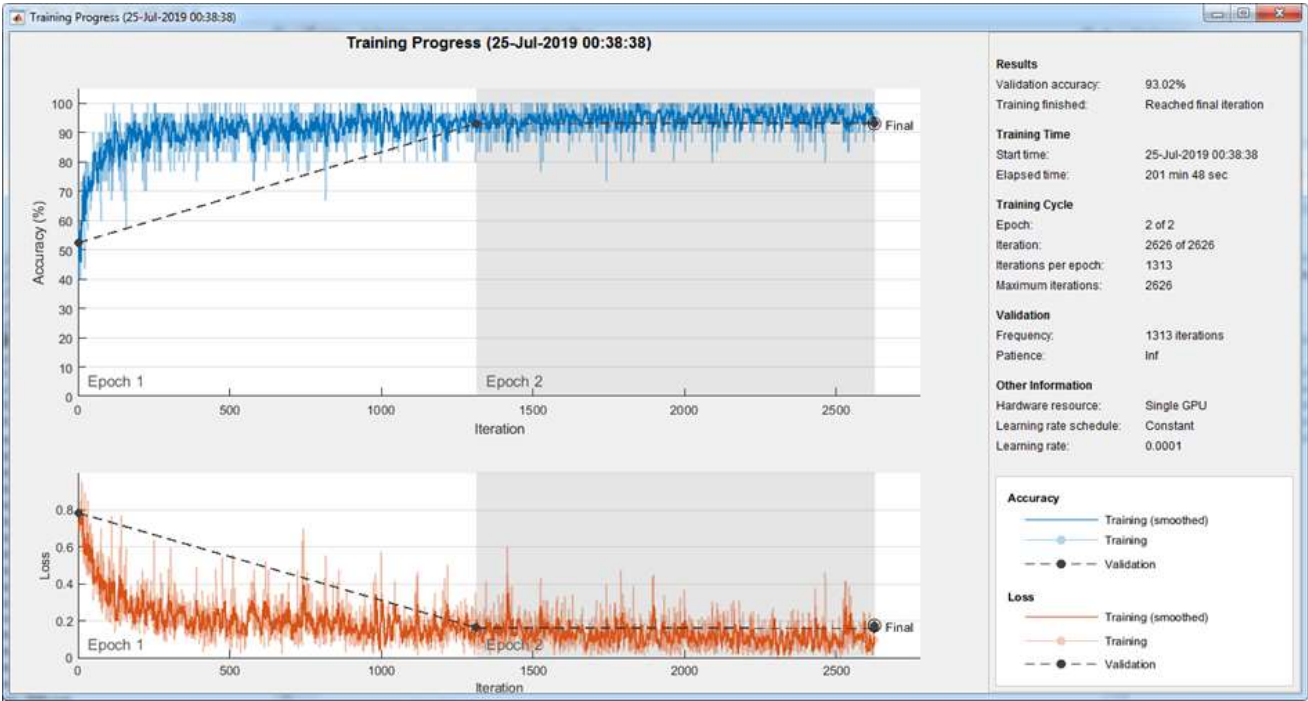
Pokus	1	2	3	4	5	Min	Max	Mean
Úspešnosť Trénovacie Data	94,66%	93,41%	94,64%	93,12%	91,47%	91,47%	94,66%	93,46%
Úspešnosť Testovacie Data	86,46%	86,89%	92,31%	90,08%	90,35%	86,46%	92,31%	89,22%

### Inception

Pokus	1	2	3	4	5	Min	Max	Mean
Úspešnosť Trénovacie Data	94,85%	92,44%	96,06%	94,02%	97,11%	92,44%	97,11%	94,90%
Úspešnosť Testovacie Data	90,29%	90,13%	93,02%	90,18%	93,37%	90,13%	93,37%	91,40%

# Aplikácie v Medicíne

## Príklad trénovania – Inception sieť



Confusion Matrix

Output Class \ Target Class	0n	1n	2n
0n	19932 50.6%	852 2.2%	95.9% 4.1%
1n	700 1.8%	17926 45.5%	96.2% 3.8%
2n	96.6% 3.4%	95.5% 4.5%	96.1% 3.9%

Confusion Matrix

Output Class \ Target Class	0n	1n	2n
0n	4870 49.4%	400 4.1%	92.4% 7.6%
1n	288 2.9%	4294 43.6%	93.7% 6.3%
2n	94.4% 5.6%	91.5% 8.5%	93.0% 7.0%



# Úspešnosť klasifikácie, senzitivita (citlivosť), špecificita

**sensitivity, recall, hit rate, or true positive rate (TPR)**

$$TPR = \frac{TP}{P} = \frac{TP}{TP + FN} = 1 - FNR$$

**specificity, selectivity or true negative rate (TNR)**

$$TNR = \frac{TN}{N} = \frac{TN}{TN + FP} = 1 - FPR$$

**precision or positive predictive value (PPV)**

$$PPV = \frac{TP}{TP + FP} = 1 - FDR$$

**negative predictive value (NPV)**

$$NPV = \frac{TN}{TN + FN} = 1 - FOR$$

**accuracy (ACC)**

$$ACC = \frac{TP + TN}{P + N} = \frac{TP + TN}{TP + TN + FP + FN}$$

**balanced accuracy (BA)**

$$BA = \frac{TPR + TNR}{2}$$

**F1 score**

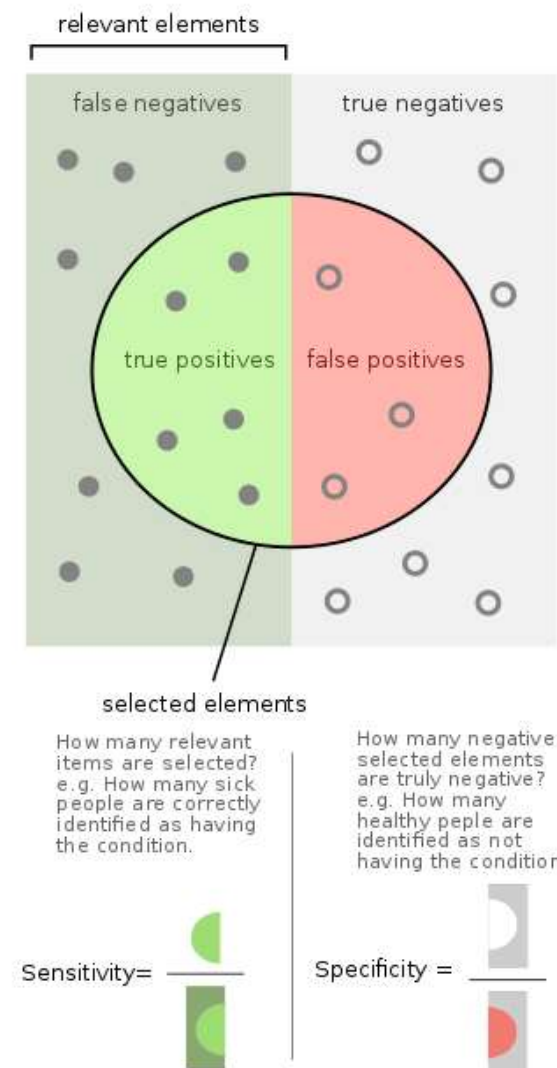
is the **harmonic mean** of **precision** and **sensitivity**

$$F_1 = 2 \cdot \frac{PPV \cdot TPR}{PPV + TPR} = \frac{2TP}{2TP + FP + FN}$$

**Confusion Matrix**

Output Class	0n	19932 50.6% <b>TN</b>	852 2.2% <b>FP</b>	95.9% 4.1% <b>TNR</b>
	1n	700 1.8% <b>FN</b>	17926 45.5% <b>TP</b>	96.2% 3.8% <b>TPR</b>
	1n	96.6% 3.4% <b>NPV</b>	95.5% 4.5% <b>PPV</b>	96.1% 3.9% <b>ACC</b>
		Target Class		

Úspešnosť




# Vizualizácia HNS

- occlusion sensitivity maps – heat maps
- CAM - class activation mapping
- Grad-CAM – gradient class activation mapping
- Deep Dream Image


# Vizualizácia HNS

- Citlivosť CNN pre klasifikáciu do triedy (occlusion sensitivity maps – heat maps)
- Zistenie, ktoré časti vstupného obrazu najviac prispievajú na priradení do danej triedy
- Demo Matlab - Understand Network Predictions Using Occlusion


miniature poodle (0.23); toy poodle (0.17); Tibetan terrier (0.11)



Occlusion sensitivity (miniature poodle)




toy poodle



# Vizualizácia HNS

- Mapovanie aktivácie tried (CAM - class activation mapping)
- Zistenie, ktoré časti vstupného obrazu najviac prispievajú na klasifikácii do jednotlivých tried
- Demo Matlab - Investigate Network Predictions Using Class Activation Mapping



Zhou, Bolei, Aditya Khosla, Agata Lapedriza, Aude Oliva, and Antonio Torralba. "Learning deep features for discriminative localization." In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 2921-2929. 2016.

# Vizualizácia HNS

- Gradientovo váhované mapovanie aktivácie tried (Grad-CAM – gradient class activation mapping)
- Zistenie, ktoré časti vstupného obrazu najviac prispievajú na klasifikácii do jednotlivých tried
- Demo Matlab - Grad-CAM Reveals the Why Behind Deep Learning Decisions






# Vizualizácia HNS


- Modifikované metódy Grad-CAM
- GradCAM++ - rovnako ako GradCAM, ale používa gradienty druhého rádu
- XGradCAM - rovnako ako GradCAM, ale škáluje gradienty podľa normalizovaných aktivácií
- ScoreCAM – vytvára obraz pomocou škálovaných aktivácií a meria pokles výstupu
- AblationCAM – vynuluje aktivácie a meria pokles výstupu



Pytorch Link: <https://github.com/jacobgil/pytorch-grad-cam>



# Vizualizácia HNS

- Vizualizácia máp príznakov – Deep Dream Image (demo - Deep Dream Images Using GoogLeNet)
- syntetizuje obrázky, ktoré silne aktivujú sieťové vrstvy
- Vizualizáciou môžete zvýrazniť vlastnosti obrázkov naučené sieťou. Tieto obrázky sú užitočné na pochopenie a diagnostiku správania siete.





Ďakujem Vám za pozornosť.  
(priestor na Vaše otázky)

